



jako řešení pro logy?

... vážně?

PR

aktuálně v { **showmax** }
ENGINEERING

devops team lead

dříve v Seznamu

architekt zastřešující projekt interního cloud řešení

project manager

částečně i product manager



Elasticsearch?

znáš a máš zkušenosti s ES?

jaké úlohy můžeš řešit díky ES?

v průměru, jaký je poměr mezi user data a indexem?

co běží v pozadí?



Otázka #1

Jak velký cluster provozuješ co do počtu nodes?



Otázka #2

Jak velký objem dat indexuješ během provozní špičky?



Question #3

Kolik dat držíš ve stavu “warm” (dostupných pro dotazování)?



Výhody vs. Nevýhody

- + dokáže zpracovat téměř cokoli
- + dynamická detekce datového typu and vytváření indexu -
- + silný DSL dotazovací jazyk
- + snadné rozběhnout a začít používat
- značné požadavky na zdroje
- celkem obtížné udržet řešení efektivní
- celkem výzva udržet řešení v chodu u velkých realizací
- cena



Cena na prvním místě

výpočetní zdroje (index/query)

v průměru, jeden node je schopen **zpracovat 20k zpráv/sec**

cena za dotazování závislá na typu a frekvenci dotazů

storage zdroje

v průměru můžeme připočítat **60% z velikosti původních dat na index**

licencování (když základ nestačí)

ne vše je možné řešit cestou open source/free software

čas engineerů



Kdysi dávno ...

předmluva

cíle projektu

jedno řešení pro všechny logy firmy

čas zpracování blíží se reálnému času

neexistující jednotná struktura logů

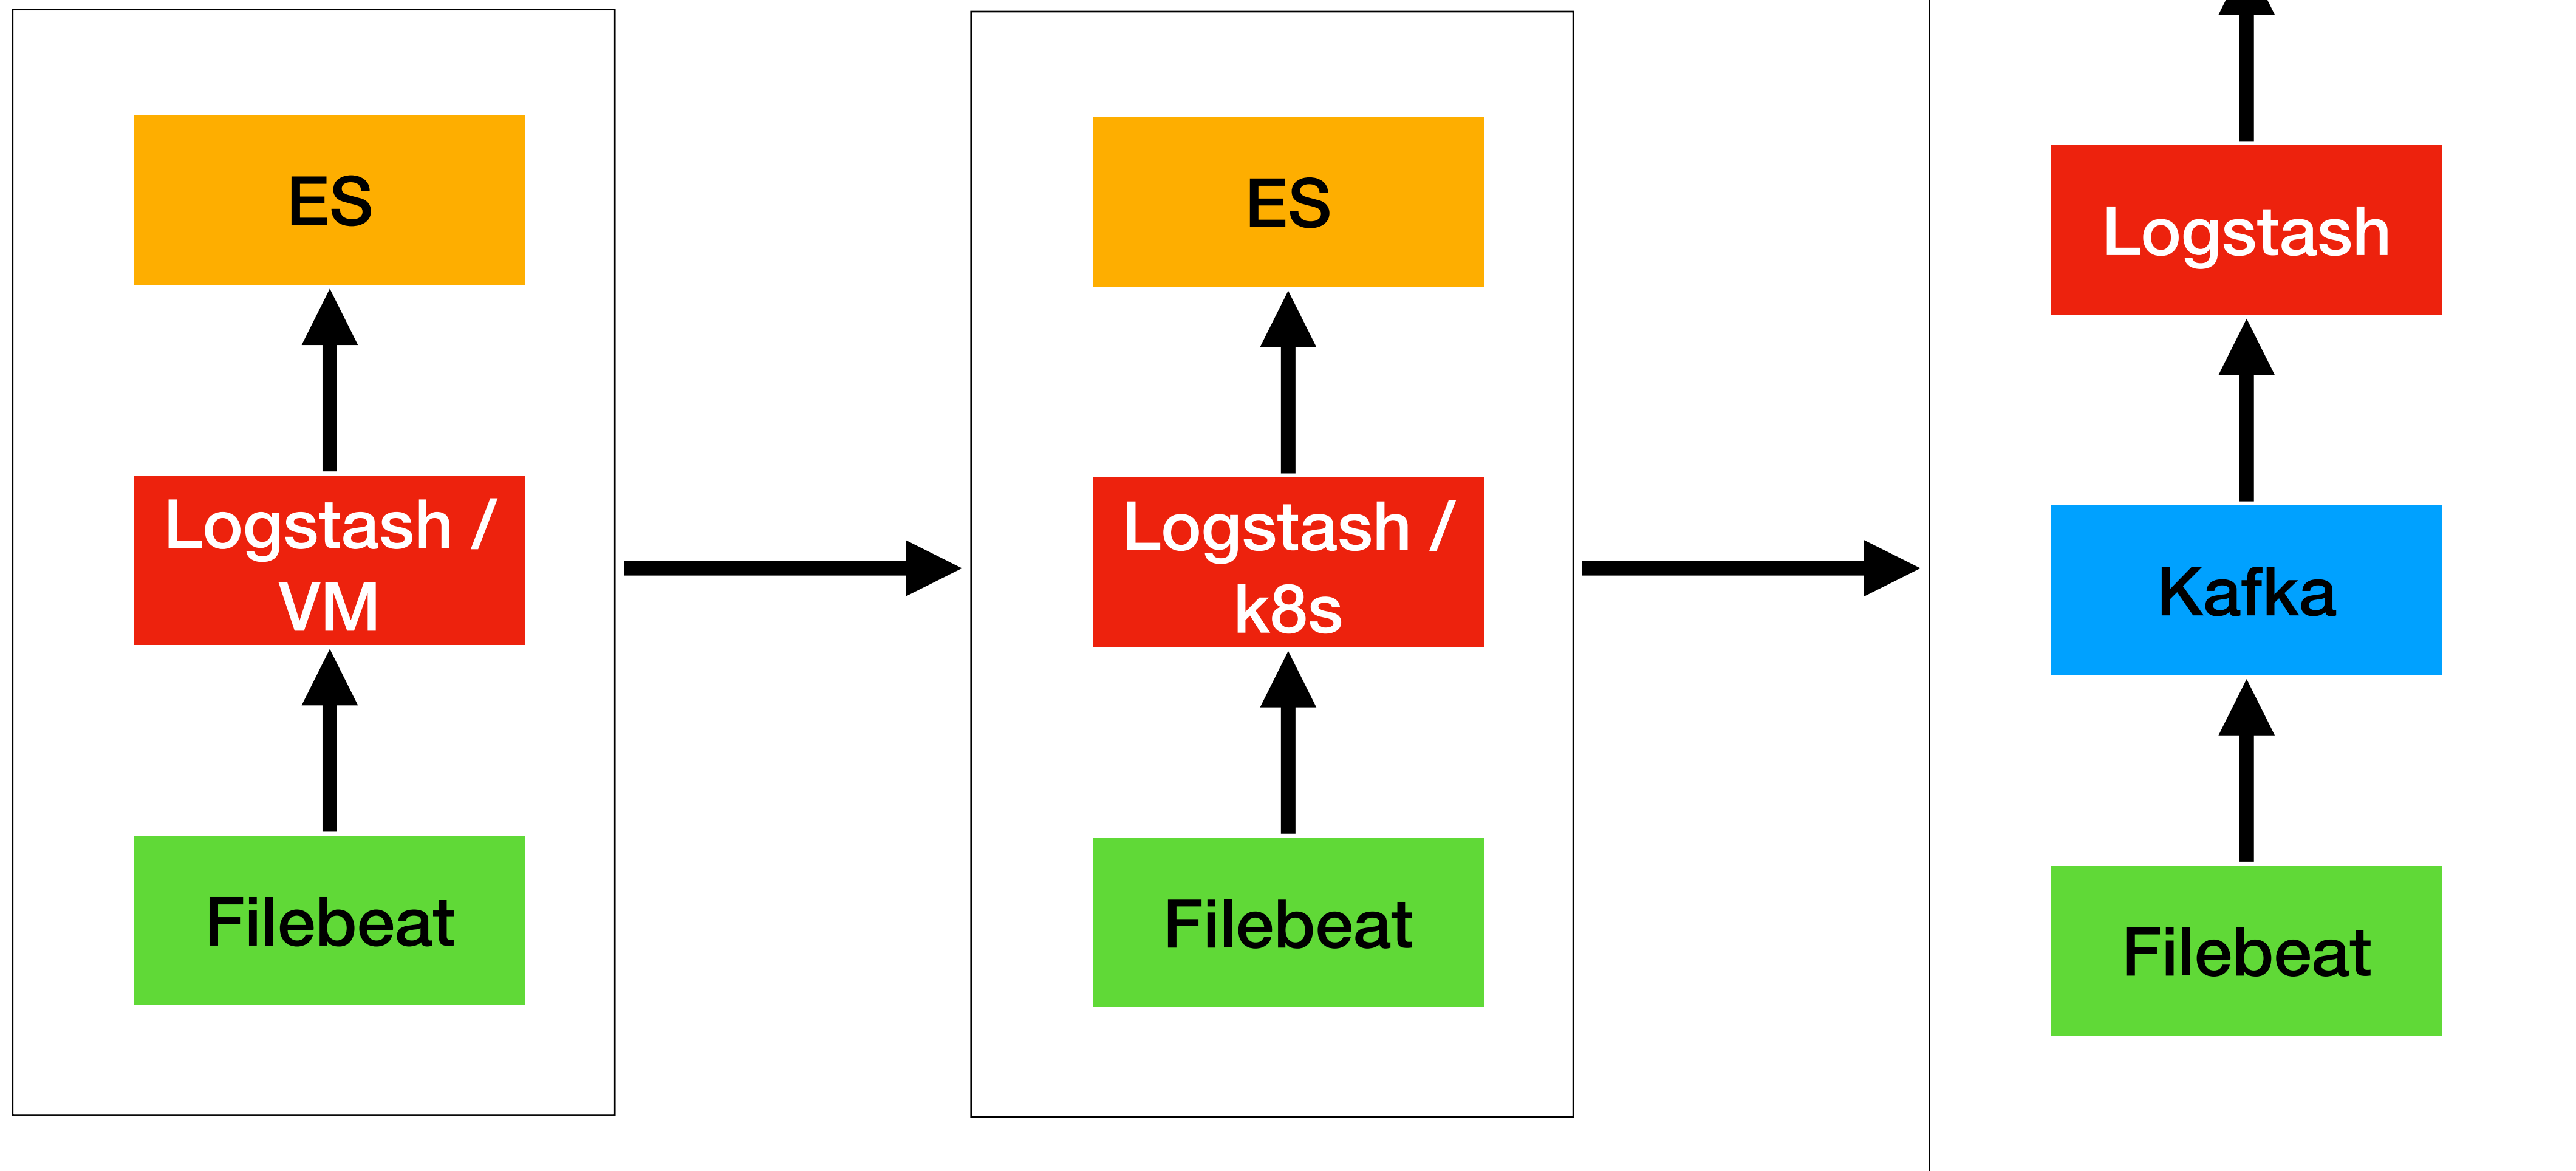
vstup ve stovkách tisíc za sekundu (prostě hodně velké číslo)

100% dostupnost

0% ztráta dat



Kdysi dávno ... příběh



Kdysi dávno ...

letíme na měsíc

vstup 400k/sec v průměru

~200TB dat dostupných pro okamžité dotazování

dostupnost řešení **docela vysoká, ale ...**

ztráta dat **docela nízká, ale ...**

data uchována v rozsahu dnů až týdnů podle typu vstupu

TLS všude a nasazen **RBAC**, aniž bychom utratili jedinou korunu



Kdysi dávno ...

nohama zpátky na zemi

ohromné množství shardů na jeden node

index field explosion

data type collisions

zastaralá verze ES

index alias != data protection



Kdysi dávno poučení

vždy následovat doporučení -> důkladně číst dokumentaci a brát ji vážně

skutečně chápat základní metriky a alertovat nad nimi

od začátku trvat na jednotné struktuře logů

neustále upgradovat ES s vysokou prioritou (např. log4shell)

omezení na počet fieldů per index je tvůj přítel

ES není Švýcarský nůž -> implementuj více tierů za použití různých produktů

měj vždy na paměti compatibility matrix



Co nějaká alternativy?

AWS OpenSearch

AWS fork originální verze Elasticsearch

přibaleno velké množství funkcionalit a stále zdarma

(cross-cluster replication, multitenancy kibana, document/field level security, ...)

můžeme provozovat on-prem nebo si zaplatit AWS aaS produkt

drží krok s novými verzemi ES

Co nějaká alternativy?

Grafana Loki

alternativní řešení pro logy od roku 2019?

zcela jiný přístup k indexování vstupu (data vs. metadata)

výrazně levnější v porovnání s řešením ES

project vznikl, aby řešil pouze zpracování logů

dobrá kandidát = základní kámen pro další tier

Díky!